

한정연

JungYun Han

AI Agent Engineer

삼성 SDS에서 생성과 검증을 분리한 Agent와 평가 데이터 루프로 LLM 품질을 지표로 개선했고, 폐쇄망 배포까지 운영했습니다. 개인 프로젝트에서는 근거 없는 인용을 차단하는 FastAPI 기반 LLM 서비스를 직접 설계해 배포했습니다.



CAREER

삼성 SDS, Senior Data Consultant (2022.10 ~)
기초과학연구원(IBS), Research Associate (2018.03 – 2022.08)

RESEARCH

이론물리학 박사, SCI 논문 4편
양자컴퓨터 특허 출원 1건 (KR 2025-0139679)

CERTIFICATE

빅데이터분석기사, 정보처리기사, OPIc IH, OPI IH

jungyun5148@gmail.com
+82-10-6305-5809
github.com/jyhanqubit
linkedin.com/in/jungyunhan5148

지표로 확인된 네 가지 성과

4 → 8회	9 → 3MM	4.0+	24h → 2h
월 평가 문항 납품 횟수	라벨링 검증 공수 절감	추천 플랫폼 만족도 (5점 만점)	물류 리스크 대응 리드타임
Agent 자동화, 리드타임 50% 단축	LLM 다수결 QA Gate 구축	후속 과제 30억 원 수주 기여	BERT 이용 이상탐지, 분기 재학습

01 AGENT DESIGN

생성과 검증을 분리한 Agent 설계

생성 Agent와 검증 Agent를 분리하고, 실제 검수에서 나온 오류를 평가 데이터로 활용했습니다.

예) 변경 전후를 같은 평가셋으로 검증해 초/중급 최초 통과율을 약 50%에서 73%로 높이고 반복 오류를 28%에서 9%로 줄였습니다.

02 VALIDATION

신뢰구간과 대조로 효과 검증

LLM 라벨의 신뢰도와 피처의 효과는 통계로 검증한 뒤에 채택했습니다.

예) LLM이 붙인 라벨은 사람 라벨 7,000건과 대조했고, 수요예측에서 뉴스 이벤트 피처의 효과는 95% 신뢰구간으로 확인했습니다.

03 SERVICE

근거로 답하고 서비스로 배포

답변의 수치는 Tool Calling으로 계산하고, Graph DB 구축으로 원문에 없는 인용은 차단했습니다.

예) GraphRAG Agent를 10문항 전수 검증해 환각 인용 10건 → 0건, 정답률 40% → 100%를 확인했고, FastAPI Endpoint 30개로 서빙하며 Contract Test 58개로 보장했습니다.

Agent 기반 시험 출제 자동화


4 → 8회

월 시험문제 납품

배경

고객사향 데이터 분석 평가 문제 제작 업무는 데이터 생성부터 문항, 정답 코드, 번역까지 수작업 비중이 높아 납기와 품질 검수에 병목이 있었습니다.

합성 데이터 검증 예시: 시간대별 전력 사용량



자동화와 품질 검증

기출문항과 채점 기준을 문항 단위로 청킹하고 **Vector DB**를 구축했습니다.

데이터셋, 문항, 정답 코드, 번역을 **역할별 Agent**로 나누고 생성 단계와 검증 단계를 분리했습니다.

Validator Agent는 생성 LLM과 다른 모델을 써서 편향을 줄이고, 정답 코드의 실행과 재현성, 누수, 합성 데이터의 분포와 정합성을 점검했습니다.

실제 검수 오류를 평가 데이터로 추가해 Agent와 프롬프트를 고도화했습니다. 초/중급 최초 검수 통과율은 약 50% → **73%**, 고급은 3% → **22%**로 올랐고 반복 오류는 28% → **9%**로 줄었습니다.

월 납품은 **4→8회**로 늘었고, 약 70회 시험을 운영하며 고급 합격률 5% 미만, 중급 20~30%, 만족도 60% 이상을 유지하고 있습니다.

생성과 검증을 분리한 Workflow + 사람 검수 후 반복(Human in the loop)

01

Vector DB 구축

기출문항, 채점 기준 임베딩

→

02

RAG 초안 생성

유사 문항과 기준을 검색해 초안 작성

→

03

역할별 Agent 처리

데이터, 문항, 정답 코드, 번역 분리

→

04

Validator 검수

실행, 재현성, 누수, 정합성 점검과 평가

사용자 피드백 (VoC) 분류 프로젝트

90%

Longformer 분류 정확도


9→3MM

라벨링 검증 공수

배경

생성형 AI GAUSS 베타테스트를 진행하며 답변 품질에 대한 사용자의 NPS를 집계했지만, 어떤 질문을 모델에 던졌을 때 답변 품질이 낮은지 알 수 없었습니다. 질문 유형을 20가지로 나눠 피드백을 분류하고, 유형별 NPS를 계산해 개선이 필요한 지점을 찾기로 했습니다.

학습 입력 토큰 길이와 모델 한계



분석과 모델 설계


질의응답이 여러 차례 이어지는 생성형 AI 특성상, 질문 의도를 파악하기 위해 질문과 모델 답변을 **하나의 입력**으로 묶었습니다.

입력 길이가 512토큰을 넘는 사례가 많아 Sparse attention으로 **2K**토큰까지 처리하는 **Longformer** 모델을 full fine-tuning했습니다.

학습 데이터는 **LLM-as-a-Judge** 방식으로 세 개 LLM이 독립 라벨링하고 만장일치 건만 자동 확정했으며, 불일치 건은 사람이 직접 검수했습니다.

기존 사람 라벨 약 7,000건과 대조한 결과, 만장일치 건의 정확도는 **95% 이상**이었으며 **95% 신뢰구간 오차폭은 ±1%p 이내**였습니다.

피드백 분석과 검증 흐름



부서별 맞춤 뉴스 추천 플랫폼 구축

4.0+

사용자 만족도 (5점 만점)

30억

후속 과제 수주 기여

배경

고객사 각 부서 담당자가 수작업으로 외부 뉴스에 대응하고 트렌드를 파악해 오던 업무였습니다. 부서를 설명하는 정형화된 데이터가 없어, 업무 맥락을 반영한 추천 기준부터 새로 만들어야 했습니다.

TF-IDF 기반 지식그래프 예시



설계와 기여

현업 인터뷰로 역할, 제품, 경쟁사, 관심 이슈를 정리해 부서를 설명하는 **페르소나**를 만들고 DB화했습니다.

코사인 유사도로 **임베딩** 벡터에서 조직별 페르소나와 가장 유사한 후보를 찾고 **CrossEncoder**로 다시 정렬해, 관련성이 높은 뉴스를 상위에 배치했습니다.

뉴스 요약과 키워드 흐름도를 LLM으로 만들어 함께 보여주었습니다.

TF-IDF **공출현 행렬 기반 지식그래프**로 신규 키워드의 맥락을 보여주고, BERT 모델로 뉴스의 고객사향 긍정/부정 요소를 분류했습니다.

부서별 클릭 로그 데이터를 바탕으로 **BPR** 등 강화학습과 **Ontology(지식그래프)**를 활용한 후속 추천 모델 고도화를 제안하였습니다.

추천 흐름

01

페르소나

부서의 역할과 관심 키워드를 정리해 부서별 시스템 프롬프트 정의

→

02

Embedding & Reranking

뉴스와 페르소나의 코사인 유사도로 뉴스 선별 후 CrossEncoder 기반 Reranking

→

03

키워드 & 뉴스 추천

LLM 추천 키워드 생성 및 부서별 뉴스 추천, 감성분석으로 긍정/부정 분류

NEXT

후속 제안

클릭 데이터로 BPR 리랭커 학습, 신설 부서의 콜드스타트는 지식그래프로 유사 부서 신호 전파

물류 리스크 이상탐지

24h → 2h

리스크 대응 리드타임

배경

삼성 SDS의 물류 담당자가 뉴스를 수작업으로 24/7 확인해 리스크에 대응했습니다. 하루에 확인할 기사가 많아 대응 리드타임이 길어졌습니다.

같은 파업 키워드, 다른 리스크: BERT를 사용한 이유

항만 파업 장기화로 선적 차질 우려

노사 합의로 항만 파업 협의 중

리스크

높음

낮음

판단과 실행

리스크 탐지 실패 비용을 줄이기 위해 Recall을 우선 지표로 정하고, 운영자가 감당할 수 있는 알림량에 맞춰 임계값을 조정했습니다.

키워드만으로는 대상과 시점을 구분하기 어려워, XGBoost로 후보를 줄인 뒤 BERT가 문맥을 읽고 위험도를 분류하는 구조로 만들었습니다.

Recall을 높인 뒤 늘어난 잘못된 알림(오탐)은 하드 네거티브 마이닝으로 정리해 분기별 재학습에 반영하는 MLOps를 운영했습니다.

운영 결과와 처리 흐름

하루 1,000건을 3~5건으로 줄였고, 평균 대응 시간은 24시간→2시간으로 단축했습니다.



1,000건

물류 뉴스 크롤링,
Hive DB 적재
수집 및 정제

< 200건

XGBoost로
Recall 기반 리스크 필터링
Word2Vec 200차원 +
리스크 유형 20개 유사도 20차원 피쳐

< 100건

요약 및 군집화
BART-CNN 요약
Clustering으로 중복 기사 제거

3~5건

운영자 자동 알림, 2시간 내 대응
BERT 심각도 분류

ShockFlow AI: 이벤트 피처 수요예측

뉴스와 도시 이벤트를 LLM으로 구조화해 수요예측 피처로 쓰고, 예측을 재배포 최적화로 연결했습니다. 결과는 FastAPI 엔드포인트 30개로 서빙하고 계약 테스트 58개로 검증했습니다. 수치 조회 도구는 MCP 서버로 분리하고 부하 테스트로 병목을 찾아 처리량을 30% 올린 뒤 배포했습니다.

① 데이터 수집 - 공유 자전거 2,491만 건 - NYC 이벤트 63,070건 - GDELT 뉴스, NOAA 날씨 - GBFS 실시간 재고	② LLM 이벤트 구조화 뉴스에서 유형, 심각도, 영향 방향을 추출하고 스키마 검증과 공개 시각 기록으로 누수 차단	③ Graph/Vector DB - Neo4j Graph DB: (5,770 노드, 11,850 엣지) - FAISS Vector DB: 의미 검색과 중복 제거	④ 수요예측 - 예측 모델: Hist GBM 실험 학습 13,630건 / 테스트 2,880건 - 이벤트 피처 유무 비교 실험	⑤ 최적화, 동적 요금 MILP 재배포 (정원, 트럭 용량, 정수 제약) 압력 점수 동적 할증 RL과 QUBO 정책 실험
--	--	--	--	---

운영 콧 — 측정 지표

모든 수치는 커밋된 reports/v2/** artifact에서 실시간으로 읽어오며, 각 지표에는 신뢰도 라벨(측정됨 / 시뮬레이션 / ...)과 출처 파일이 함께 표시됩니다. 하드코딩된 숫자는 없습니다. research 결과는 운영 화면에 노출되지 않습니다.

H3 multi-holdout WAPE

0.4828

측정됨

The promoted model's aggregate H3 multi-holdout WAPE is 0.4828 (measured).

출처: reports/v2/holdout/h3_multiholdout.json#aggregate.wape.mean
run: run_v2-01_20260720T121350Z_f1a28b37

Served model

hist_gradient_boosting

측정됨

The promoted (served) model is hist_gradient_boosting.

출처: reports/v2/holdout/promoted_model.json#algorithm
run: run_v2-01_20260720T121350Z_f1a28b37

Forecast profit vs no-action

\$103,271

시뮬레이션

가정 하 추정 · 제품 결정용 아님

The promoted forecast nets \$103,271 more than the seasonal-naive baseline (simulated, assumption-conditioned).

출처: reports/v2/ledger/profit_regression.json#predictive_lift_to_profit.model_minus_no_action_net
run: run_v2-02_20260720T124240Z

Best rebalancing policy

mpc

시뮬레이션

가정 하 추정 · 제품 결정용 아님

The best feasible rebalancing policy is mpc (Oracle is an offline bound, excluded).

출처: reports/v2/mpc/policy_comparison.json#ranking_by_total_cost
run: run_v2-04_20260721T034058Z

운영 콧: 측정 지표를 신뢰도 라벨과 출처로 표기

🔗 운영 도우미에게 물어보세요

as-of 이벤트 그래프에 근거해 답합니다. GPT/Claude 키를 설정하면 GraphRAG(LLM)로, 없으면 규칙 기반으로 자동 동작합니다 (오프라인 · 임의 SQL 없음 · 숫자는 대시보드와 동일 출처).

지금 현황

부족 대여소

수요 급증

요금 상태

물어보기

🚩 규칙 기반

현재 가동률 48% (614/1284대), 부족 대여소 14곳, 반영 이벤트 0건입니다.

운영 통계 열기 →

운영 도우미: 근거 기반 답변(수치는 MCP 도구 5종으로 조회)

-1.24%

수요예측 WAPE 상대 개선

위치가 국지적인 이벤트만 유효한 조건부 개선

-73%

재배치 부족 감소

재배치 없이 둘 때 대비 MPC 최적화

10/10

근거 인용 원문 일치

GraphRAG 근거 검증 (질문 10개)

① 구조화된 도시 이벤트로 급락 예측 보완

검증 1-5월 학습(13,630건), 6월 데이터로 최종 평가(2,880건)

누수 차단 Point-in-time join으로 예측 시점 이전 공개 정보만 결합

효과 Hist GBM 분위 회귀(0.667분위)로 품질 26%, 비용 3.4% 감소, WAPE 증가

통계 WAPE 상대 1.24% 개선(6월 창, 시드 10개 앙상블), 95% CI [0.83, 1.64]%

인사이트 국지적 이벤트만 정확도 개선(+1.24%), 전역 이벤트는 캘린더 피처와 겹쳐 정확도 저하

② 예측을 재배치 최적화로 연결

비교 기준 가까운 거점부터 옮기는 Greedy 방식

최적화 MILP(HiGHS)로 제약 만족 최적해, 다기간 (MPC)으로 확장

효과 재배치 부재 대비 부족 73% 감소, Greedy 대비 총비용 36% 감소(시뮬레이션 정책 평가)

최적성 MILP 해가 소규모 문제의 전수 비교 최적해와 일치

정책 비교 완벽 예측 정책 대비 추가 비용 (낮을수록 좋음): MPC 21.6\$, PPO 202.9\$, Q-learning 247.8\$

③ 답변의 원문 근거까지 검증

검색 방식 GraphRAG로 사건과 출처를 연결해 근거 탐색

채점 RAGAS faithfulness 1.0, answer relevancy 0.985, MCP 도구 라우팅 1.0

효과 검색 없는 LLM 대비 환각 10건 → 0건, 정답 0/10 → 10/10(grounding만 4/10)

안전장치 원문 없는 인용 차단, API 부재 시 규칙 기반 대체, MCP 장애 시 in-process 대체

구조 수치 조회 도구 5개를 표준 프로토콜(MCP) 서버로 분리, 답변마다 출처 표기 유지. 분리 전후 정확도 동일, 오버헤드 p50 3~5ms

한정연

JungYun Han, AI Agent Engineer

삼성 SDS에서 RAG와 Agent 기반 자동화, LLM full fine-tuning, 사내 vLLM 서빙 플랫폼 위 Agent 오케스트레이션 설계까지 수행했고, 개인 프로젝트에서 FastAPI 기반 LLM 서비스를 설계해 배포했습니다.

CAREER

삼성 SDS, Senior Data Consultant (2022.10~)

EDUCATION

2022 UST 이론물리학 박사 (IBS 캠퍼스)

2018 서울대학교 물리학 석사

2015 연세대학교 물리학 학사

CERTIFICATION

빅데이터분석기사, 정보처리기사
OPIc IH, OPI IH

양자광학, 양자정보 관련 SCI 논문 4편
양자컴퓨터 특허 출원 (KR 2025-0139679)

SKILLS

Programming	Python (PyTorch, Hugging Face, scikit-learn, pandas), FastAPI, Pydantic, REST API
Database	SQL (HiveQL, PostgreSQL), Vector DB (FAISS), Graph DB (Neo4j)
Language Model	Embedding Model(BGE-M3), CrossEncoder, GPT, BERT, Longformer, Full fine-tuning, PEFT, sLLM
ML / Optimization	회귀, 분류, 통계 검정, 앙상블(XGBoost, LightGBM), 시계열 예측, MILP 기반 MPC 최적화, 모델 A/B 테스트
Generative AI	RAG, GraphRAG, Multi-Agent 설계, LangChain, LangGraph, Tool Calling, LLM-as-a-Judge, RAGAS, MCP
Infrastructure	SCP (삼성클라우드), 사내 보안망(온프레미스 폐쇄망), Docker, GitLab CI, 부하 테스트와 성능 튜닝